

Informe de análisis NILM

Desagregación no intrusiva de cargas eléctricas | Medición: 10 de abril

Objetivo

Inferir los equipos o modos de operación presentes en una instalación a partir de una medición eléctrica agregada, sin sensores individuales por máquina.

Muestras

8,477

Duración

23.54 h

Energía

163.93 kWh

Pico

34.55 kW

Eventos

795

Clústeres

4

Configuración reproducida

Detección: $\Delta I \geq 2 \text{ A}$ o $\Delta P \geq 1 \text{ kW}$. Agrupamiento: K-Means con 4 grupos, normalización StandardScaler y semilla aleatoria 42.

Cómo se construye la firma eléctrica

Variables calculadas antes de aplicar Machine Learning

1. Limpieza

Fecha + hora → timestamp ordenado. Columnas eléctricas → valores numéricos.

2. Magnitudes

I_total, V_avg, PF_avg, P_total, S_total, Q_total y THD_avg.

3. Cambios

ΔI , ΔP y ΔQ entre muestras consecutivas.

4. Eventos

Se conservan las transiciones positivas que superan los umbrales.

5. Firma

Cada evento se representa como [ΔP , ΔI , THD, ΔQ].

6. Clustering

StandardScaler + K-Means, GMM o DBSCAN.

Fórmulas principales

$$I_{\text{total}} = I_{L1} + I_{L2} + I_{L3}$$

$$Q = \sqrt{\max(0, S^2 - P^2)}$$


$$P = (V_{\text{avg}} \cdot I_{\text{total}} \cdot PF_{\text{avg}}) / 1000 \quad S = (V_{\text{avg}} \cdot I_{\text{total}}) / 1000$$

$$\Delta x_t = x_t - x_{(t-1)}$$

Señal agregada y eventos detectados

La detección busca saltos eléctricos compatibles con arranques o cambios de carga

Potencia agregada y transiciones positivas




Nube 3D de actividad eléctrica

Corriente y tensión en el plano inferior; tiempo en el eje vertical

Eventos agrupados por firma eléctrica


- Auxiliares / Standby (1.4 kW)
- Variador / Carga Electrónica
- Auxiliares / Standby (-0.5 k
- Compresor / Motor Principal




Espacios de características

Separación visual de los eventos según potencia, corriente, reactiva y distorsión

ΔP vs ΔQ



ΔI vs THD



Algoritmos e identificación de equipos

Qué calcula el sistema y qué parte corresponde a inferencia heurística

Algoritmos

K-Means: asigna eventos a centroides y es el método predeterminado. GMM: modela grupos como distribuciones gaussianas y permite solapamiento probabilístico. DBSCAN: agrupa por densidad y puede encontrar eventos atípicos.

Reglas de interpretación

El clustering encuentra grupos eléctricos, pero no conoce el nombre físico del equipo. Después se aplican reglas: $\Delta P \geq 25 \text{ kW}$ o $\Delta I \geq 40 \text{ A}$ → motor/compresor principal; $\text{THD} \geq 40 \%$ → variador/carga electrónica; $\Delta P \geq 8 \text{ kW}$ → bomba/ventilador; $\Delta P \geq 2 \text{ kW}$ → motor mediano; el resto → auxiliar/standby.

Bibliotecas

Backend: pandas para datos tabulares, NumPy para cálculo numérico, scikit-learn para K-Means/GMM/DBSCAN/StandardScaler y Tornado para la API. Frontend: TypeScript y Canvas HTML5 para los gráficos, sin una biblioteca 3D externa.

Interpretación y próximos pasos

Resultados actuales y recomendaciones para una identificación más robusta

Qué significa el resultado

La aplicación identifica patrones de consumo y los agrupa según su firma eléctrica. Los nombres mostrados son categorías inferidas, no una confirmación del modelo exacto de la máquina.

Limitaciones actuales

La potencia se estima a partir de tensión, corriente y factor de potencia; la detección actual prioriza transiciones positivas; la duración se estima buscando caídas de potencia; y los umbrales de identificación son reglas fijas.

Mejoras recomendadas

Validar contra mediciones individuales por equipo, incorporar eventos de apagado, usar duración y armónicos como características, entrenar un clasificador supervisado con etiquetas reales y evaluar precisión, recall, F1 y error de energía.

Conclusión

El sistema actual constituye una base funcional de NILM: detecta cambios, construye firmas, agrupa eventos y reconstruye curvas aproximadas por carga.